



Momento de Retroalimentación: Redefinición de los datos

Hector Kenneth Ramos Velazquez | A01642284

Fecha: 02 de septiembre del 2026.

1.- Introducción

Esta continuación tiene como propósito implementar manualmente una técnica clásica de ML, sin que esta use frameworks especializados de ML, a partir de los datos REHAB.

Este dataset contiene señales registradas mediante sensores durante la ejecución de diferentes ejercicios relacionados con rehabilitación. Para este análisis se hizo uso de la sección de Rehab_exercise, tomando en cuenta los archivos correspondientes al sensor 2 de las 16 actividades identificadas 000 a 015.

Cada repetición contiene 880 observaciones temporales y seis canales de medición: f1,f2,f3,f4,f5 y pitch3. A partir del análisis exploratorio realizado previamente se observó que la combinación de varios canales podía aportar información útil para diferenciar estas actividades, por lo que se generó una nueva representación de los datos mediante características estadísticas. Posteriormente se implementó desde cero el algoritmo K-Nearest Neighbors (KNN) para realizar la clasificación.

2.- Descripción del dataset

El conjunto contiene 16 actividades registradas mediante dos sensores.

La cantidad de repeticiones varía dependiendo de la actividad, mientras que la longitud temporal y el número de canales permanecen constantes.

Elemento	Valor
Actividades	16
Identificadores	000-015
Archivos utilizados	16
Sensor utilizado	sensor 2
Canales	6
Lecturas por repetición	880
Repeticiones originales	4.616

3.- Validación y limpieza de los datos

3.1 Validación de archivos

Antes de construir el modelo se realizó una validación de los 16 archivos. Se comprobó que cada archivo pudiera cargarse de manera correcta, que presentara tres dimensiones, que mantuviera 880 observaciones temporales y seis canales, y que no contuviera valores de Nan o infinitos.

Los 16 archivos se validaron de manera correcta, obteniendo un conjunto de 4616 repeticiones.

Validación	Resultado
Archivos revisados	16
Archivos correctos	16
Valores Nan	0
Valores infinitos	0
Repeticiones Originales	4,616

3.2 Repeticiones en cero

Durante esta revisión de las repeticiones se identificó un patrón que aparecía 68 veces bajo diferentes etiquetas de actividad.

Al inspeccionar estos valores se comprobó que corresponde a una matriz de tamaño 880 x 6 formada completamente por ceros:

- Valor mínimo: 0,
- Valor máximo: 0,

- Media: 0,
- Desviación Estándar: 0,
- 5,280 valores iguales a cero

Debido a que esta señal no contenía información de movimiento y aparecía asociada con diferentes actividades, se optó por eliminar las 68 apariciones de este patron.

3.3 Repeticiones duplicadas

Para detectar repeticiones exactamente iguales se generó un identificador mediante SHA-256 a partir de los 5,280 valores de cada repetición.

En una revisión inicial se identificaron 725 ocurrencias duplicadas adicionales. Dentro de ellas se encontraba el patrón formado por ceros descrito anteriormente.

Después de eliminar las 68 repeticiones completamente en cero, quedaron 658 repeticiones duplicadas exactas adicionales. Para cada grupo de duplicados se conservó únicamente una copia.

Por ende, el dataset pasó de 4,616 repeticiones originales a 3,890 repeticiones finales.




Imagen 1 : Repeticiones originales y finales por actividades después del proceso de limpieza.

La imagen permite observar que el efecto de la limpieza no fue igual para todas las actividades. Algunas conservaron prácticamente todas sus repeticiones, mientras que otras presentaron una reducción mayor debido principalmente a la presencia de duplicados.

4.- Construcción de nuevo dataset

4.1 Extracción de las características

Cada repetición original contiene $880 \times 6 = 5280$ valores.

Para obtener una representación más compacta y adecuada para un algoritmo clásico de aprendizaje automático, se calcularon cinco características estadísticas para cada uno de los seis canales:

- Media
- Desviación estándar
- Valor mínimo
- Valor máximo
- Rango

Por lo que $5 \text{ características} \times 6 \text{ canales} = 30 \text{ características por repetición}$.

Característica	Descripción
Media	Valor promedio del canal
Desviación estándar	Variabilidad de la señal
Mínimo	Menor valor observado
Máximo	Mayor valor observado
Rango	Diferencia entre máximo y mínimo

La elección de estas características también se relaciona con los resultados del reporte de EDA, donde se observó que algunas actividades presentaban valores centrales similares pero diferencias importantes en su variabilidad y distribución.

4.2 Estructura final

El nuevo dataset se guardó como: rehab_features.csv

Cada fila representa una repetición y contiene:

- 30 características numéricas
- 1 etiqueta correspondiente a la actividad

Elemento	Resultado
Muestras finales	3890
Características	30
Etiqueta	Actividad
Columnas totales	31
Nan	0
Infinitos	0
Patrones duplicados	0
Conflictos de etiqueta	0

Después de la extracción se volvió a realizar un análisis y ya no se encontraron características idénticas duplicadas.

5. Implementación manual de KNN

5.1 Selección del algoritmo

Para realizar la clasificación se utilizó el algoritmo K-Nearest Neighbors (KNN).

KNN clasifica una nueva observación a partir de las etiquetas de las muestras más cercanas dentro del conjunto de entrenamiento. A diferencia de otros modelos, no ajusta coeficientes durante una fase de entrenamiento, sino que utiliza las muestras almacenadas para calcular las distancias cuando se realiza una predicción.

La implementación fue realizada de manera manual en Python. No se utilizaron algoritmos de machine learning ya implementados mediante herramientas como el scikit-learn.

NumPy se utilizó únicamente para operaciones matemáticas y manejo de arreglos.

5.2 División de los datos

Para seleccionar el valor de K se realizó una división estratificada de aproximadamente:

- 70% para entrenamiento
- 15% para validación
- 15% para prueba

La división se realizó de manera independiente para cada una de las 16 actividades, con el objetivo de mantener representación de todas las clases.

Valores conseguidos :

Conjunto	Muestras
Entrenamiento	2715
Validación	577
Prueba	598
Total	3,890

Se utilizó una semilla fija de 42 para que la división pudiera reproducirse al ejecutar nuevamente el programa.

5.3 Normalización Min-Max

Debido a que las características extraídas poseen escalas diferentes, se aplicó normalización Min-Max.

Los valores mínimo y máximo fueron calculados exclusivamente con el conjunto de datos de entrenamiento. Posteriormente, esos mismos valores fueron utilizados para transformar los datos de validación y prueba.

Esto evita utilizar información del conjunto de prueba durante la preparación del modelo.

La normalización resulta especialmente relevante ya que el EDA mostró que el canal pitch3 posee una escala y variabilidad considerablemente distintas a los canales de flexión f1-f5.

5.4 Distancia euclidiana

Para cada nueva muestra se calculó su distancia respecto a todas las muestras disponibles en entrenamiento.

Las distancias fueron ordenadas de menor a mayor y posteriormente se seleccionaron los K vecinos más cercanos.

La predicción corresponde a la actividad con mayor cantidad de votos entre estos vecinos. En un caso de empate, se selecciona la clase del vecino más cercano entre las clases empatadas.

6. Selección del valor de K

Se probaron cinco valores de K utilizando exclusivamente el conjunto de validación:

K	Accuracy de validación
1	92.20%
3	81.28%
5	69.50%

7	66.38%
9	62.05%




Imagen 2: muestra que el mejor rendimiento se obtuvo con $K = 1$, alcanzando un accuracy de validación de 92.20%, conforme incrementa el número de vecinos considerados, el rendimiento disminuyó. Debido a estos resultados, se tomó $K = 1$ para la configuración final del clasificador.

7. Evaluación Final

7.1 Configuración del modelo final

Después de seleccionar $K=1$ mediante el conjunto de validación, los conjuntos de entrenamiento y validación fueron combinados para aprovechar una mayor cantidad de las muestras.

Configuración:

Conjunto	Muestras
Entrenamiento final	3,292
Prueba	598

Estos parámetros de normalización fueron recalculados utilizando únicamente las 3,292 muestras del conjunto de entrenamiento final.

7.2 Resultado general

El modelo realizó predicciones sobre las 598 muestras del conjunto de prueba


Resultados:

Resultado	Valor
K seleccionado	1
Predicciones totales	598
Predicciones correctas	566
Predicciones incorrectas	32
Accuracy global	94.65%

Este modelo clasificó correctamente 566 de las 598 muestras de prueba, obteniendo un accuracy global de 94.65%.

8. Resultados por actividad

Para mayor detalle el comportamiento del modelo se calculó el porcentaje de muestras correctamente clasificadas para cada una de estas 16 actividades.



Actividad	Correctas	Total	Porcentaje de aciertos
000	28	28	100.00%
001	29	30	96.67%
002	25	27	92.59%
003	30	30	100.00%
004	42	42	100.00%
005	43	43	100.00%
006	32	33	96.97%
007	57	58	98.28%
008	39	46	84.78%
009	37	47	78.72%
010	35	38	92.11%
011	29	29	100.00%
012	31	31	100.00%
013	39	42	92.86%
014	39	41	95.12%
015	31	33	93.94%


El modelo logró clasificar correctamente el 100% de las muestras correspondientes a las actividades 000,003,004,005,011 y 012.

Las actividades que presentaron el menor porcentaje de aciertos fueron:

- Actividad 008: 84.78%
- Actividad 009: 78.72%

Por lo tanto, la actividad 009 presentó la mayor dificultad de clasificación dentro del conjunto de prueba.

9.- Matriz de confusión



La matriz de confusión permite analizar con mayor detalle los errores cometidos por el clasificador. Las filas representan las actividades reales, mientras que las columnas representan las actividades predichas.

La mayor concentración de valores se encuentra sobre la diagonal principal, lo que corresponde a predicciones correctas.

Las confusiones que fueron más frecuentes fueron las siguientes:

- Actividad real 008 predicha como la 011: 4 veces
- Actividad real 010 predicha como la 006: 3 veces
- Actividad real 009 predicha como la 008: 3 veces
- Actividad real 009 predicha como la 003: 3 veces
- Actividad real 013 predicha como la 014: 2 veces
- Actividad real 009 predicha como la 012: 2 veces
- Actividad real 009 predicha como la 007: 2 veces

Todos estos resultados demuestran que la act 009 no solo representa el menor porcentaje de aciertos, sino que también fue confundida con varias actividades diferentes.

10.- Discusión

Los resultados obtenidos muestran que la representación basada en las 30 características estadísticas conserva suficiente información para distinguir la mayoría de las actividades del dataset REHAB.

El KNN implementado manualmente alcanzó un accuracy global de 94.65% sobre el conjunto final de prueba.

Sin embargo, el desempeño no fue uniforme en todas las actividades. La actividad 009 presentó el menor porcentaje de aciertos, con un 78.72% seguida de la actividad 008, con 84.78%.

Este comportamiento presenta relación con observaciones realizadas durante el EDA. La actividad 009 mostró una mayor dispersión y un traslape considerable con otras actividades en algunas de las distribuciones.

Asimismo, el análisis multivariado previo mostró que podían existir regiones de traslape entre actividades incluso al utilizar varios canales simultáneamente.

Otro dato importante fue el comportamiento del hiperparámetro K . El mejor desempeño de validación se obtuvo con $K=1$. Al incrementar K a 3,5,7 y 9, el accuracy disminuyó progresivamente. Esto indica que, bajo la representación utilizada, las muestras más cercanas contienen información especialmente útil para identificar la actividad, mientras que al ampliar el vecindario comienzan a incorporarse observaciones correspondientes a otras clases.

11. Limitaciones

Esta evaluación realizada presenta algunas limitaciones que deben considerarse al interpretar los resultados.

Primero, la división del dataset se realizó a nivel de repetición. Por lo tanto, el accuracy obtenido representa el desempeño del modelo sobre repeticiones separadas para prueba bajo los datos usados.

No se realizó una separación específica por participante, por lo que estos resultados no deben interpretarse como evidencia directa de generalización hacia sujetos completamente nuevos.

Además, la representación utilizada resume cada señal temporal mediante cinco características estadísticas por canal. Aunque este procedimiento permitió reducir considerablemente la dimensionalidad de los datos, también implica que parte de la información relacionada con la evolución temporal de los movimientos no se utiliza de manera directa.

12.- Conclusiones

Para esta retroalimentación se implementó manualmente el algoritmo de K-Nearest Neighbors , para clasificar las actividades del dataset de REHAB.

Después del proceso de validación y limpieza, las 4616 repeticiones originales se redujeron a 3890 muestras, así eliminando repeticiones de cero y duplicados exactos. Cada repetición fue representada mediante las 30 características estadísticas extraídas de los 6 canales.

El mejor desempeño se obtuvo con $K = 1$. En la evaluación final, el modelo clasificó correctamente 566 de 598 muestras, alcanzando un accuracy global de 94.65%

Por lo que en general, los resultados muestran que la implementación manual de KNN fue capaz de distinguir correctamente la mayoría de las actividades, aunque las clases 008 y 009 fueron las que presentaron una mayor dificultad de clasificación.